Prova AEDI — Risco Cibernético por Simulação de Monte Carlo (ANDI)

Relatório técnico — Grupo 5 — semente 202605 Disciplina: Análise Estatística de Dados e Informações (PPCA) — Prof. João Carlos Félix Souza

> **RASCUNHO PARA REVISÃO DO GRUPO.** Texto e código produzidos com apoio de IA (ver `memorial_ia.md`). Todos os números vêm de `saidas/resultados.md`, gerado por `uv run python main.py --grupo 5`. As interpretações precisam ser conferidas, ajustadas e assumidas pelo grupo antes da entrega.

Convenções: α = 5%; valores em reais; "mi" = milhões. Tabelas completas em `saidas/tabelas/` e figuras em `saidas/figuras/`.

Parte A — O modelo gerador

Questão 1 — Implementação

a) Os quatro passos da Seção 12.2 no código. O gerador está em `andi/gerador.py`, e o cabeçalho do módulo registra a correspondência:

Passo (Seção 12.2)	Onde está	O que faz
1. Modelar	`parametros.py`; `taxa_trimestral`, `taxa_mensal`, `prob_materializacao`, `log_mediana_perda`	Distribuições, coeficientes e as relações entre entradas e saídas
2. Sortear	`gerar_unidades` (A1), `sortear_ataques` (A2–A5), com `sorteio.py`	Um valor de cada entrada incerta, por transformação inversa de U
3. Calcular	`sortear_ataques`, `montar_bases`, `derivar_painel_trimestral`, `derivar_serie_mensal`	Taxa → contagem → atributos → p_i → perda; depois as cinco bases
4. Analisar	`parte_a.py`, `parte_b*.py`, `parte_c.py`	Verificação, capítulos 1 a 11 e a SMC de decisão

O comando único recria as bases bit a bit (conferido: duas execuções produzem `ataques.csv` idêntico). Resultado com a semente 202605: 24 unidades (13 com SOC), **3.063 ataques**, **1.288 perdas**, painel de 288 linhas e série de 36 meses.

Decisões de implementação que o enunciado deixa em aberto (todas documentadas no código):

- Gerador uniforme: PCG64 do NumPy, um único fluxo iniciado com a semente; ordem fixa dos sorteios A1 → A2 → A3 → A4 → A5.
- Fevereiro tem sempre 28 dias (o enunciado fixa "28, 30 ou 31"), inclusive em 2024.
- Arredondamentos: patch e treino com 2 casas, cvss com 1, tempo com 2, perda em centavos. O logit e a severidade usam os valores já arredondados, de modo que os CSV bastam para reconstruir p_i.
- As análises da Parte B leem os CSV gravados, não os objetos em memória.

b) Como cada distribuição sai de um uniforme. Todas usam a transformação inversa $X = F^{-1}(U)$, $U \sim \text{Uniforme}[0, 1)$:

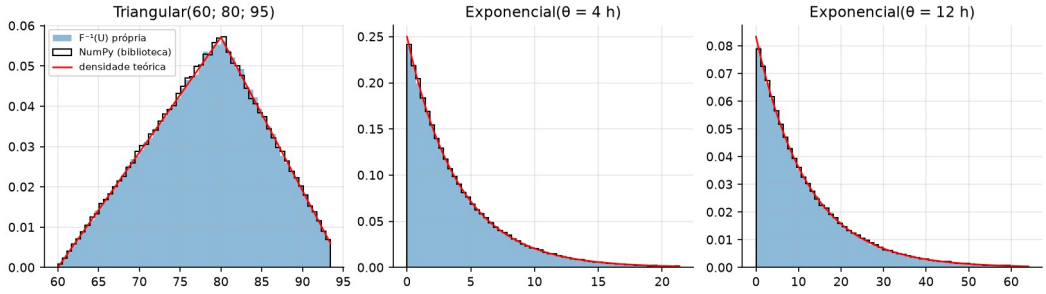
Distribuição	Uso	Transformação
Uniforme contínua (a; b)	treino	$x = a + (b - a)\cdot U$
Uniforme discreta {a..b}	servicos, dia	$x = a + \lfloor (b - a + 1)\cdot U \rfloor$
Bernoulli (p)	soc, fora_expediente, materializou	$x = 1$ se $U < p$
Categórica	tipo	menor k com $p_1 + \ldots + p_k > U$
Triangular (a; c; b)	patch, cvss	$F_c = (c - a)/(b - a)$. Se $U < F_c$: $x = a + \sqrt{U(b - a)(c - a)}$; senão: $x = b - \sqrt{(1 - U)(b - a)(b - c)}$
Exponencial (θ)	tempo de detecção	$F(x) = 1 - e^{-x/\theta} \Rightarrow x = -\theta\cdot\ln(1 - U)$
Poisson (λ)	contagem mensal	menor n com $F(n; \lambda) \geq U$ (busca na acumulada)
Normal	ruído da perda	$z = \Phi^{-1}(U)$, inversão numérica

A Triangular e a Exponencial foram escritas à mão (`sorteio.py`) e comparadas com as funções prontas em 200.000 sorteios:

	Triangular (60; 80; 95)	Exponencial θ = 4	Exponencial θ = 12
Média teórica	78,333	4,000	12,000
Média F^{-1} própria	78,352	4,010	12,030

Média NumPy	78,311	3,996	12,027
Desvio teórico	7,169	4,000	12,000
Desvio F^{-1} própria	7,167	4,010	12,030
Máx. |própria − ppf SciPy| (mesmo U)	0,00000	0,00000	0,00000
KS p-valor (própria)	0,308	0,308	0,308
KS p-valor (NumPy)	0,009	0,493	0,318

Com o mesmo U, a inversa própria coincide com a ppf do SciPy até a precisão de máquina, e médias e desvios ficam a menos de 0,3% do teórico. O p-valor KS é igual nas três colunas da inversa própria porque as três usam o mesmo U e a estatística KS não muda sob transformação monótona. O p = 0,009 da amostra NumPy da Triangular é flutuação: repetindo com oito outras sementes, os p-valores ficaram entre 0,21 e 1,00.



Inversa própria x biblioteca

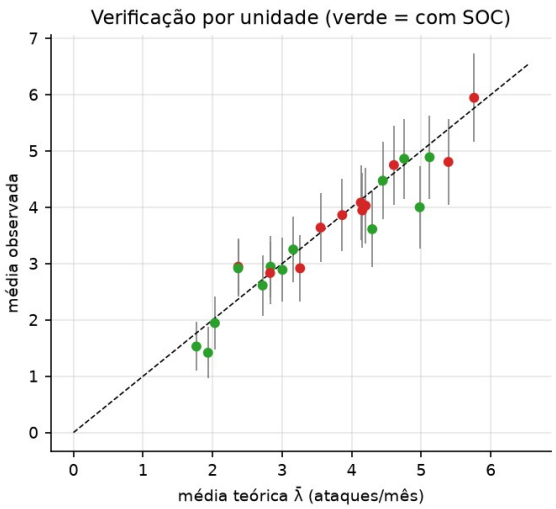
c) Justificativa das distribuições (tabela da Seção 12.4).

Entrada	Distribuição	Por quê
Nº de ataques por unidade-mês	Poisson	Contagem de ocorrências por período
soc, fora_expediente, materializou	Bernoulli	Ocorre / não ocorre
tipo	Categórica	Generalização da Bernoulli para seis categorias
patch, cvss	Triangular	Incerteza limitada: só se conhece mínimo, moda e máximo
servicos, treino, dia	Uniforme	Só a faixa plausível, sem valor preferido
tempo de detecção	Exponencial	Tempo de espera até um evento
perda	Lognormal	Positiva, assimétrica, de cauda pesada

Usar a Normal para a severidade seria grave por três motivos, e os dados confirmam cada um. Com a média (R$ 72.709) e o desvio (R$ 171.283) observados, uma Normal daria 33,6% de probabilidade a perdas negativas, que não existem. Ela é simétrica, enquanto a perda tem assimetria 10,0 e 76% dos casos abaixo da média. E ela subestima a cauda: sob a Normal, a maior perda (R$ 3,41 mi) estaria a 19,5 desvios da média, evento impossível, mas ela ocorreu em 1.288 observações. Como 10% das perdas respondem por 52% do valor perdido (Questão 4-b), errar a cauda é errar o risco.

Questão 2 — Verificação do gerador

a) Média mensal por unidade. A tabela `q02a_media_unidade` compara, para cada unidade, a média observada em 36 meses com a média de λ_{u,t}. No agregado, foram 3.063 ataques contra 3.151,3 esperados (z = −1,57): compatível. Por unidade, 5 das 24 ficaram além de ±1,96 erro padrão (U03, z = −2,63; U17, +2,24; U18, −1,98; U22, +2,14; U24, −2,23), contra 1,2 esperada. Como quatro delas estão na fronteira, o teste conjunto é mais informativo: Σz^2 = 32,5 com 24 graus de liberdade, p = 0,116. Não há evidência de erro no gerador. Uma checagem independente, com 2.000 histórias de 36 meses, deu diferença máxima de 0,013 ataque/mês entre a média simulada e $\bar{\lambda}$ de qualquer unidade.



Média observada x teórica

b) Variância x média. Dentro de cada unidade sem SOC, o índice de dispersão (variância/média) variou de 0,81 a 1,36, com média 1,02: é o que a Poisson exige. O valor não é exatamente 1 por dois motivos: são só 36 observações por unidade, e λ muda no tempo (tendência, sazonalidade, campanha), o que soma Var(λ_t) à variância.

Juntando as 864 unidades-mês, a média é 3,55 e a variância 4,99: índice de 1,41. A decomposição explica: a variância total é a média das variâncias internas (3,90) mais a variância entre as médias das unidades (1,20). Cada unidade é Poisson com a sua taxa, mas a mistura de taxas diferentes é superdispersa. Para a ANDI, isso significa que um único λ "médio" para todas as unidades subestimaria a variabilidade; a taxa precisa depender do perfil, como faz a regressão da Questão 11.

c) Tipos e materialização.

Tipo	Programada	Observada	Diferença	Erro de simulação	z
Phishing	0,350	0,3366	−0,0134	0,0086	−1,56
Força bruta	0,200	0,2040	+0,0040	0,0072	+0,56
Malware	0,150	0,1610	+0,0110	0,0065	+1,70
Exploração de vuln.	0,150	0,1430	−0,0070	0,0065	−1,09
DDoS	0,100	0,1084	+0,0084	0,0054	+1,55
Ransomware	0,050	0,0470	−0,0030	0,0039	−0,76

Todas as diferenças estão dentro de ±1,96·√(p(1−p)/n); o qui-quadrado de aderência dá 7,98 (5 g.l.), p = 0,158. A taxa de materialização foi 42,05%, contra 43,04% de média dos p_i; com erro de simulação de 0,79 p.p., z = −1,25. As diferenças têm a ordem de grandeza σ/√n da Seção 12.3: com n ≈ 3.000, uma proporção é estimada com cerca de ±1 a ±2 p.p. Para cortar esse erro pela metade seriam precisos 12.000 ataques.

Parte B — Análise das bases

Questão 3 — Dos dados à decisão (cap. 1)

a) Classificação.

Coluna	Tipo de variável
id_ataque, id_perda	Qualitativa nominal (identificador)
unidade, tipo	Qualitativa nominal
data	Quantitativa contínua (tempo), tratada como discreta em dias
ano, mes, trimestre	Quantitativa discreta (ordinais quando usadas como rótulo de período)
fora_expediente, materializou	Qualitativa nominal binária
cvss	Quantitativa contínua (escala de 0 a 10, registrada com 1 casa)
tempo_deteccao_h, perda_rs	Quantitativa contínua

Quanto à estrutura, `ataques.csv` e `perdas.csv` são dados em nível de evento (uma linha por ocorrência, com data); `unidades.csv` é corte transversal; `serie_mensal.csv` é série temporal; `painel_trimestral.csv` é painel (24 unidades × 12 trimestres).

- **População:** todos os ataques que o processo gerador da ANDI pode produzir, incluindo os de 2026.
- **Amostra:** os 3.063 ataques de janeiro de 2023 a dezembro de 2025.
- **Unidade de observação:** o ataque (ou a unidade-trimestre e o mês, nas bases derivadas).
- **Parâmetros:** os valores populacionais desconhecidos para o analista: taxa de ataques, probabilidade de materialização, média e dispersão da perda, coeficientes dos modelos.

b) Distribuições de frequências. Phishing é o tipo mais frequente (1.031; 33,7%), seguido de força bruta (625; 20,4%), malware (493; 16,1%), exploração de vulnerabilidade (438; 14,3%), DDoS (332; 10,8%) e ransomware (144; 4,7%). Os três primeiros acumulam 70,2%.

Para `perda_rs`, Sturges dá $K = 1 + 3{,}322 \cdot \log_{10}(1.288) = 11{,}3 \approx 11$ classes; com início em 0 e amplitude conveniente de R$ 310.000:

Classe (R$)	f	fr	F	Fr
0 ⊢ 310.000	1.247	0,9682	1.247	0,9682
310.000 ⊢ 620.000	25	0,0194	1.272	0,9876
620.000 ⊢ 930.000	6	0,0047	1.278	0,9922
930.000 ⊢ 1.240.000	4	0,0031	1.282	0,9953
1.240.000 ⊢ 1.550.000	3	0,0023	1.285	0,9977
1.550.000 ⊢ 1.860.000	1	0,0008	1.286	0,9984
1.860.000 ⊢ 2.170.000	1	0,0008	1.287	0,9992
2.170.000 ⊢ 3.100.000 (3 classes)	0	0	1.287	0,9992
3.100.000 ⊢ 3.410.000	1	0,0008	1.288	1,0000

A tabela mostra a forma da variável: 96,8% das perdas na primeira classe e uma cauda longa até R$ 3,4 mi. Classes de mesma amplitude descrevem mal uma variável assim; em ln(perda) as mesmas 11 classes formam um sino quase simétrico (tabela `q03b_classes_ln_perda`).

c) Média, mediana e moda.

Tipo	n	Média	Mediana	Moda (Czuber)	Média/mediana
Phishing	386	34.144	19.881	10.091	1,72
Força bruta	193	20.529	13.178	7.465	1,56
Malware	220	62.053	39.154	25.768	1,58
Exploração de vuln.	245	97.260	57.654	35.240	1,69
DDoS	138	56.124	38.039	18.983	1,48
Ransomware	106	295.111	149.281	102.189	1,98
Geral	1.288	72.709	31.711	10.991	2,29

A moda foi calculada por Czuber com classes mais finas (amplitude 2·AIQ/n^(1/3)), porque com as classes de Sturges a classe modal é sempre a primeira e a fórmula devolve um valor sem sentido.

A ordem moda < mediana < média, em todos os tipos, é a assinatura da assimetria à direita. A **mediana** representa melhor a perda típica de um incidente: metade dos incidentes custa menos de R$ 31,7 mil, e só 23,9% custam mais que a média. A média é puxada por poucos eventos extremos. Ela continua sendo a medida certa para orçamento, porque a perda anual é a soma das perdas e somas dependem da média. A leitura para a diretoria: o incidente típico custa cerca de R$ 32 mil, mas o orçamento deve prever R$ 73 mil por incidente.

Questão 4 — Dispersão, formato e associação (cap. 2)

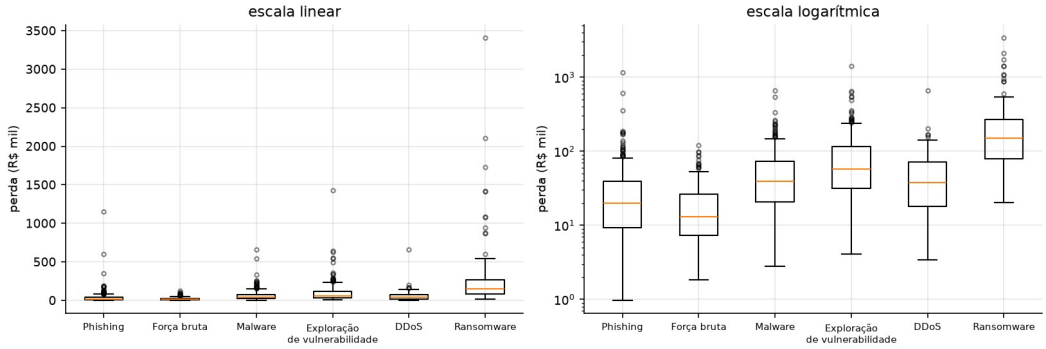
a) Dispersão por tipo.

Tipo	Desvio-padrão	CV	AIQ	AIQ/mediana
Phishing	72.552	2,13	29.954	1,51
Força bruta	20.087	0,98	18.873	1,43
Malware	76.229	1,23	52.890	1,35
Exploração de vuln.	131.536	1,35	83.253	1,44
DDoS	66.912	1,19	54.078	1,42
Ransomware	467.954	1,59	186.853	1,25

Em termos absolutos o ransomware domina: desvio de R$ 468 mil, seis vezes o do phishing. Em termos relativos, o maior CV é o do **phishing** (2,13), seguido do ransomware (1,59). O CV do phishing é inflado por uma única perda de R$ 1,15 mi, de um ataque detectado só após 120,8 h; a medida robusta AIQ/mediana fica entre 1,25 e 1,51 para todos os tipos. Isso é coerente com um mesmo σ logarítmico para todos: a dispersão relativa é

parecida entre tipos, e o que muda é a escala. Todos os CV ficam perto ou acima de 1: em qualquer tipo, o desvio é do tamanho da média.

b) Box-plots e outliers.



Box-plots da perda por tipo

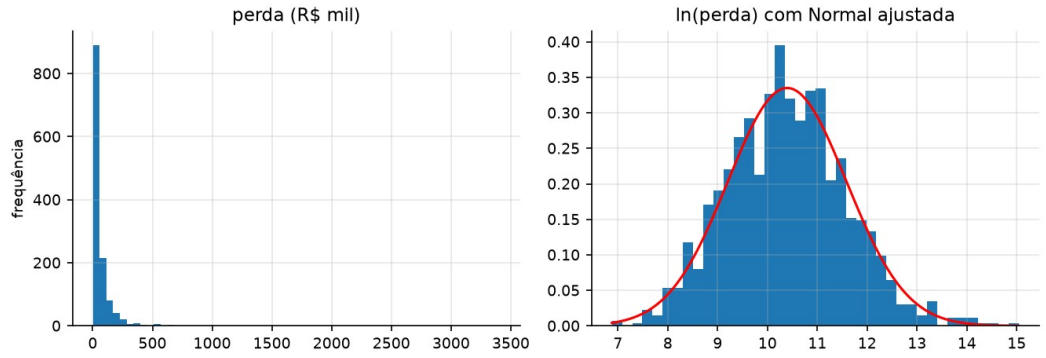
Tipo	Cerca superior (R$)	Outliers acima	% das perdas	% do valor do tipo
Phishing	84.095	24	6,2	35,3
Força bruta	54.434	13	6,7	25,6
Malware	153.116	21	9,5	37,3
Exploração de vuln.	239.830	19	7,8	33,5
DDoS	153.042	5	3,6	17,5
Ransomware	546.748	11	10,4	49,7

Não há outliers abaixo (as cercas inferiores são negativas). No conjunto, 130 perdas (10,1%) estão acima da cerca e somam **52,3% de todo o valor perdido**. Esses pontos não são erros de registro: são o resultado esperado de uma distribuição de cauda pesada, e em escala logarítmica quase desaparecem. Removê-los cortaria metade do risco da base e levaria a um VaR falsamente baixo. São a essência do risco e devem ficar.

c) Assimetria e curtose.

	perda_rs	ln(perda_rs)
Assimetria	10,02	0,24
Curtose (Normal = 3)	148,9	3,21
Média / mediana	72.709 / 31.711	10,40 / 10,36

O logaritmo transforma uma distribuição extremamente assimétrica e leptocúrtica em algo muito próximo da Normal: assimetria quase nula, curtose 3,2, média e mediana praticamente iguais. É a evidência descritiva de que a perda é aproximadamente Lognormal. A leve assimetria que sobra (0,24) vem da mistura de tipos e do efeito do tempo de detecção.



Histogramas da perda e de ln(perda)

d) Covariâncias e correlações (painel, n = 288).

	n_ataques	perda_total	servicos	patch	treino	soc
n_ataques	1	0,400	0,619	−0,040	−0,195	−0,253
perda_total		1	0,204	0,008	−0,114	−0,331
servicos			1	−0,060	0,002	−0,163
patch				1	0,073	−0,319

treino					1	−0,080
soc						1

A matriz de covariâncias (tabela `q04d_covariancias`) tem os mesmos sinais, mas magnitudes incomparáveis por causa das unidades (a variância de perda_total é $2{,}5 \times 10^{11}$). Os sinais seguem o esperado: mais serviços expostos, mais ataques (0,62, a associação mais forte); treinamento e SOC, menos ataques. O SOC se associa mais à perda (−0,33) do que à contagem (−0,25), porque atua em três frentes: frequência, materialização e severidade. A correlação de patch com ataques é quase nula (−0,04). Isso não significa que patch não funcione: o efeito programado é pequeno diante do ruído, e nesta amostra as unidades com SOC têm, por acaso, menos cobertura de patches (r = −0,32), o que confunde a leitura bivariada. A correlação entre ataques e perda é só 0,40 porque a perda de um trimestre depende de poucos eventos grandes.

e) VaR histórico de 95% da perda mensal. O percentil 95 de `serie_mensal.perda_total` é **R$ 4,91 mi**, para uma média mensal de R$ 2,60 mi: em 1 mês a cada 20, a ANDI perderia mais que isso. Com 36 observações, o percentil 95 é uma interpolação entre a maior perda (R$ 6,30 mi, abril de 2025) e a segunda (R$ 5,54 mi, agosto de 2023); a estimativa depende de dois pontos, um deles o mês da campanha. O intervalo bootstrap de 95% vai de R$ 3,56 mi a R$ 6,30 mi. Com 36 meses esperam-se apenas 1,8 observações acima do VaR, e o histórico não pode mostrar perdas maiores do que as já vistas. Essa é a limitação que a SMC da Parte C resolve.

Questão 5 — Probabilidade e Bayes (cap. 3)

a) Contingência tipo × materializou.

Tipo	Não materializou	Materializou	Total	P(mat | tipo)	P(tipo | mat)
Phishing	645	386	1.031	0,374	0,300
Força bruta	432	193	625	0,309	0,150
Malware	273	220	493	0,446	0,171
Exploração de vuln.	193	245	438	0,559	0,190
DDoS	194	138	332	0,416	0,107
Ransomware	38	106	144	0,736	0,082
Total	1.775	1.288	3.063	0,421	1,000

As probabilidades conjuntas são as contagens divididas por 3.063 (tabela `q05a_conjuntas`); por exemplo, P(ransomware ∩ materializou) = 0,0346.

P(materializou | ransomware) = 106/144 = 0,736, mas **P(ransomware | materializou) = 106/1.288 = 0,082**. O numerador é o mesmo; muda a base de referência. A primeira pergunta "dos ataques de ransomware, quantos viram perda?" (quase três em quatro: é o tipo mais perigoso). A segunda pergunta "das perdas, quantas são de ransomware?" (poucas, porque o ransomware é raro: 4,7% dos ataques). Confundir as duas é a falácia da condicional invertida. Na gestão: diante de um ransomware, tratar como perda quase certa; mas a maior parte dos incidentes com perda vem de phishing (30%), pelo volume.

b) Independência entre SOC e materialização. Com A = "ataque em unidade com SOC" e B = "materializou": P(A) = 0,4858, P(B) = 0,4205, P(A)·P(B) = 0,2043, mas P(A ∩ B) = 0,1401. Não são independentes. Em termos condicionais: P(B | SOC) = 0,288 contra P(B | sem SOC) = 0,545. O qui-quadrado de independência (207,5; $p \approx 5 \times 10^{-47}$) confirma que não é acaso. Ter SOC reduz a chance de um ataque virar perda quase pela metade.

c) Triagem "alarme se cvss ≥ 7".

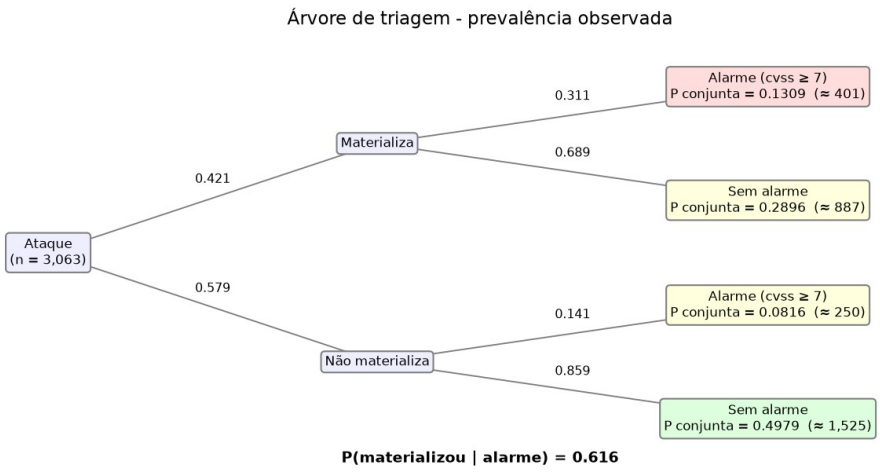
	Materializou	Não materializou
Alarme	401	250
Sem alarme	887	1.525

Sensibilidade = 401/1.288 = 0,311; especificidade = 1.525/1.775 = 0,859; prevalência = 0,4205. Pelo Teorema de Bayes:

P(mat | alarme) = (0,311 × 0,4205) / (0,311 × 0,4205 + 0,141 × 0,5795) = 0,1309 / 0,2125 = **0,616**

A contagem direta dá 401/651 = 0,616: os dois caminhos coincidem. A regra é um filtro fraco: quando dispara, acerta 62% das vezes, mas deixa passar 69% das perdas (887 de 1.288). O CVSS mede gravidade técnica; a materialização depende também do tempo de detecção, do SOC e do treinamento.

d) Árvore de triagem e prevalência pela metade.



Árvore de triagem

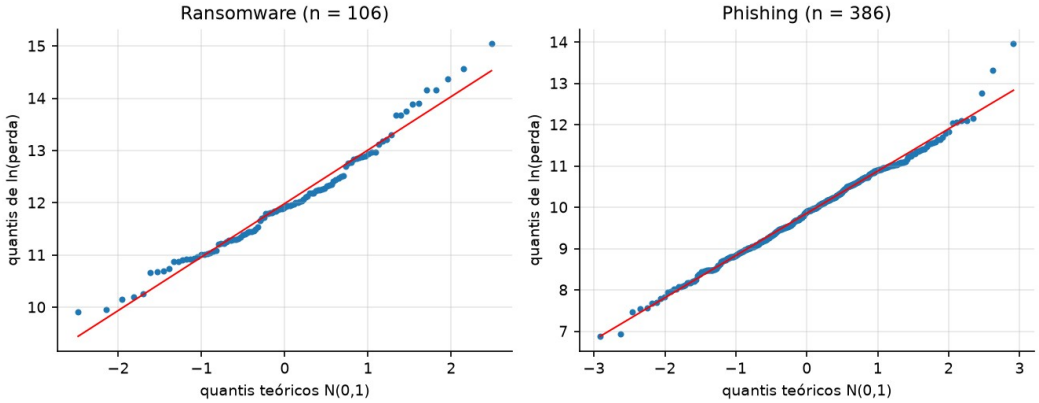
Se a prevalência caísse para 21,0% (por exemplo, com o pacote de controles), mantidas sensibilidade e especificidade, o valor preditivo do alarme cairia de 61,6% para **37,1%**: quase dois em cada três alarmes seriam falsos. Com prevalência de 5%, só 10%. É o efeito da taxa-base da Seção 3.8: o mesmo alarme vale menos quanto mais raro o evento. Uma consequência prática para a ANDI: se os controles funcionarem, a regra de triagem precisa ser recalibrada, ou a equipe passará a perseguir falsos alarmes.

Questão 6 — Distribuições (cap. 4 e 5)

a) Poisson. Escolhemos a U06, a unidade sem SOC mais atacada (28 serviços, patch de 73%, 1,25 h de treino), com média de 5,94 ataques por mês. Pela Poisson, P(N ≥ 6) = 1 − F(5; 5,94) = **0,545**. Empiricamente, 21 dos 36 meses tiveram 6 ou mais ataques: **0,583**. A diferença (0,038) é menos da metade do erro padrão de uma proporção com n = 36 (0,083). O modelo descreve bem a unidade, que deve se preparar para 6 ou mais ataques em mais da metade dos meses. O mesmo acordo aparece nas outras dez unidades sem SOC (tabela `q06a_poisson`).

b) Exponencial. Para unidades com SOC e ataques em expediente (n = 976), o tempo médio observado é 3,88 h e o desvio 3,66 h (média ≈ desvio, como na Exponencial). A probabilidade teórica de passar de 8 h é e^(−8/3,88) = **0,127** com θ estimado (e e^{-2} = 0,135 com θ = 4 do gerador). A proporção observada é **0,127**. Mesmo com SOC e em expediente, um em cada oito ataques leva mais de 8 h para ser detectado: a média de 4 h não é um teto.

c) Q-Q de ln(perda) e escore Z.



Q-Q de ln(perda)

	Ransomware	Phishing
n	106	386
Média / desvio de ln(perda)	11,99 / 1,02	9,85 / 1,02
Correlação do Q-Q	0,987	0,996
Shapiro-Wilk p	0,032	0,132
Assimetria de ln(perda)	0,57	0,14
Maior perda (R$)	3.407.216	1.151.367
Z da maior, em ln	2,99	4,02
Z da maior, em R$	6,65	15,40

Os pontos seguem a reta nos dois tipos; a hipótese Lognormal se sustenta como aproximação. No phishing, a normalidade de ln(perda) não é rejeitada. No ransomware é rejeitada por pouco (p = 0,032), com cauda direita um pouco acima da reta. Isso tem explicação no gerador: a perda é Lognormal *condicionada* ao tempo de detecção; sem condicionar, ln(perda) é Normal mais 0,02 × tempo, e o tempo é Exponencial, assimétrico à direita. A mistura tem cauda um pouco mais pesada que a Lognormal pura.

O escore Z mostra por que a escala importa. Em reais, a maior perda de phishing está a 15,4 desvios da média, o que seria impossível sob uma Normal. Em logaritmo está a 4,0 desvios: ainda rara (esperaríamos 0,01 caso assim em 386), e explicada pelo tempo de detecção de 120,8 h daquele ataque, que sozinho soma 2,4 ao logaritmo. A maior perda de ransomware (Z = 2,99 em ln) é rara, mas plausível em 106 observações.

Questão 7 — Amostragem e estimação (cap. 6)

a) IC de 95% para o tempo médio de detecção.

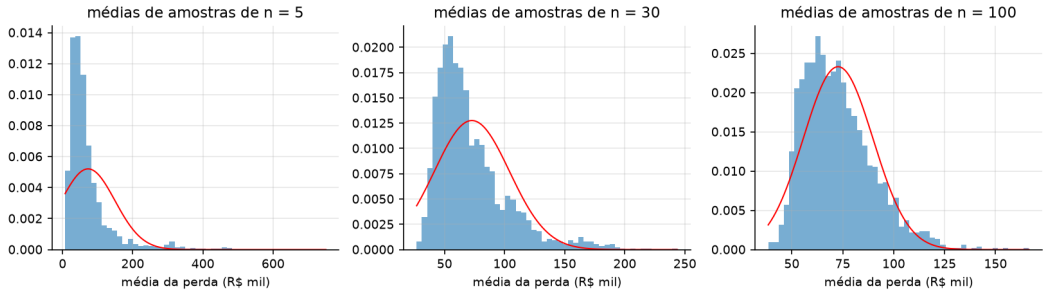
Grupo	n	Média (h)	IC 95%	θ programado	Contém θ?
Com SOC, todos	1.488	4,51	[4,28; 4,75]	4	Não
Com SOC, só expediente	976	3,88	[3,65; 4,11]	4	Sim
Sem SOC, todos	1.575	14,39	[13,64; 15,14]	12	Não
Sem SOC, só expediente	996	11,94	[11,20; 12,68]	12	Sim

Os intervalos com todos os ataques **não** contêm os θ programados, e isso não é erro de estimação. θ é a média da Exponencial antes do multiplicador de 1,5 aplicado aos 35% de ataques fora do expediente. A média populacional do tempo é θ × (0,65 + 0,35 × 1,5) = 1,175·θ: 4,70 h com SOC e 14,10 h sem. Os dois intervalos contêm esses valores. Restringindo aos ataques em expediente, os intervalos contêm 4 e 12. O IC estimou corretamente o parâmetro da população amostrada; a comparação ingênua é que mirava outro parâmetro.

b) Proporção de materializados. $\hat{p}$ = 0,4205; IC 95% = 0,4205 ± 1,96·√(0,4205 × 0,5795 / 3.063) = **[0,403; 0,438]**. Para margem de ±2 p.p.: n = 1,96² × 0,4205 × 0,5795 / 0,02² = **2.341 ataques** (2.401 no caso conservador p = 0,5). A base atual, com 3.063, já entrega margem de ±1,75 p.p.

c) Teorema Central do Limite. A população é a própria base de perdas (μ = R$ 72.709; σ = R$ 171.283; assimetria 10,0). Em 2.000 amostras com reposição:

	n = 5	n = 30	n = 100
Média das médias (R$)	72.521	72.096	72.616
Desvio das médias (R$)	68.480	30.269	17.052
σ/√n (R$)	76.600	31.272	17.128
Assimetria das médias	3,31	1,60	0,94
Curtose em excesso	15,3	3,1	1,3



TCL com perda_rs

Duas previsões do TCL se confirmam: a média das médias fica em μ, e o desvio das médias segue σ/√n (razão de 0,97 em n = 30 e 1,00 em n = 100). A terceira, a forma Normal, chega devagar: em n = 30 a distribuição das médias ainda tem assimetria 1,6, e em n = 100 ainda 0,9. A regra prática "n ≥ 30" supõe uma população moderadamente assimétrica; com assimetria 10 e cauda pesada, uma única perda extrema domina a média de 30. Para a ANDI: intervalos de confiança para a perda média baseados em poucas dezenas de incidentes são otimistas no limite superior. Em ln(perda), a convergência seria imediata.

Questão 8 — Testes de hipóteses e backtesting (cap. 7)

a) Tempo médio de detecção com SOC (contrato: no máximo 4 h).

1. H_0: $\mu \leq 4$ h (contrato cumprido); H_a: $\mu > 4$ h.
2. Estatística t (σ desconhecido), n = 1.488.
3. α = 5%, unilateral à direita.
4. Rejeitar H_0 se t > t(0,05; 1.487) = 1,646.
5. $\bar{x}$ = 4,514; s = 4,684; t = (4,514 − 4)/(4,684/√1.488) = **4,23**; p-valor = $1{,}2 \times 10^{-5}$.
6. Rejeita-se H_0: o tempo médio de detecção nas unidades com SOC é maior que 4 h. O contrato não está sendo cumprido.

O resultado parece contradizer o gerador (θ = 4 h), mas não contradiz. O contrato fala do tempo médio de todos os ataques, e os 35% que chegam fora do expediente levam 50% mais tempo: a média verdadeira é 4,70 h. Repetindo o teste só com ataques em expediente, t = −1,03 (p = 0,85) e H_0 não é rejeitada. O SOC entrega 4 h no expediente e descumpre o contrato à noite e nos fins de semana. A ação é cobertura fora do expediente, e não trocar o SOC.

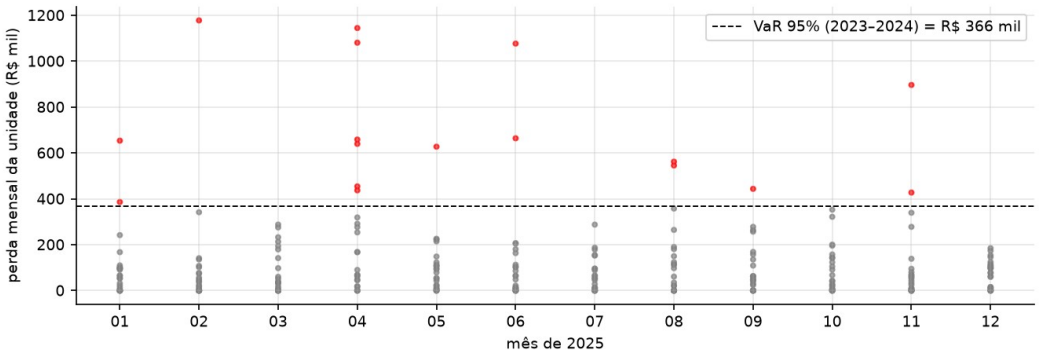
b) Meta de no máximo 40% de materialização.

7. H_0: $p \leq 0{,}40$; H_a: $p > 0{,}40$.
8. Estatística Z para proporção.
9. α = 5%, unilateral à direita.
10. Rejeitar H_0 se z > 1,645.
11. $\hat{p}$ = 0,4205; z = (0,4205 − 0,40)/√(0,40 × 0,60/3.063) = **2,32**; p-valor = 0,010.
12. Rejeita-se H_0: a proporção de ataques materializados supera a meta. A diferença é pequena (2 p.p.), mas estatisticamente clara com 3.063 ataques.

c) Erros do item (a). Erro Tipo I: concluir que o SOC descumpre o contrato ($\mu > 4$ h) quando ele cumpre. Custo: disputa contratual indevida, multa ou troca de fornecedor sem motivo. Erro Tipo II: não rejeitar H_0 quando o tempo médio real passa de 4 h. Custo: a ANDI segue acreditando numa detecção mais rápida do que a real. Como cada hora de atraso aumenta a chance de materialização (razão de chances de 1,06 por hora, Questão 13) e encarece a perda em cerca de 2% (Questão 9), o **Tipo II é o mais caro**: é um risco que não aparece em nenhum relatório. Isso justificaria até um α maior neste teste, para ganhar poder.

d) Backtesting do VaR (Kupiec).

13. H_0: a proporção de exceções é 5% (modelo adequado); H_a: é diferente de 5%.
14. Estatística LR de Kupiec, qui-quadrado com 1 g.l.
15. α = 5%.
16. Rejeitar H_0 se LR > 3,84.
17. VaR de 95% estimado em 2023–2024 (576 unidades-mês): **R$ 365.992**. Em 2025 (T = 288), N = **17 exceções** (5,9%), contra 14,4 esperadas. LR = **0,47**; p-valor = 0,494.
18. Não se rejeita H_0: o VaR histórico de 2023–2024 não é rejeitado em 2025.



Backtesting

O modelo não foi rejeitado, embora saibamos que o gerador mudou entre os períodos (tendência de alta e campanha em abril de 2025). Três razões:

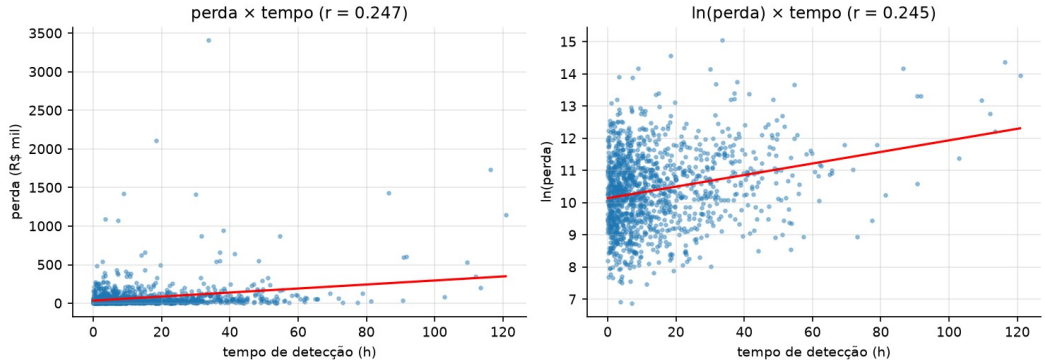
- A tendência é pequena diante do ruído. A taxa cresce 0,15 por trimestre sobre um nível próximo de 11; a perda média por unidade-mês foi de R$ 107,9 mil em 2023–2024 para R$ 109,4 mil em 2025.

- A campanha aparece, mas concentrada: abril de 2025 teve 6 exceções em 24 unidades (25%), contra 1,2 esperada. Kupiec só conta o total de exceções, e não vê que elas se agruparam num mês. Um teste de independência das exceções capturaria isso.
- Poder baixo: com T = 288 e p = 5%, o teste só rejeitaria com 23 ou mais exceções. Sem abril, são 11 em 264 (LR = 0,41).

Não rejeitar é diferente de validar. O teste de Kupiec deixou passar duas mudanças que sabemos existir.

Questão 9 — Correlação e regressão simples (cap. 8)

a) Dispersão e correlação.



Dispersão perda × tempo

	r	t (1.286 g.l.)	p-valor
perda × tempo	0,247	9,13	< 0,0001
ln(perda) × tempo	0,245	9,06	< 0,0001

Nos dois casos rejeita-se H_0: ρ = 0. A correlação é positiva e fraca. Os dois r são quase iguais, mas o diagrama em reais é dominado por poucos pontos extremos e tem variância crescente, enquanto em logaritmo a nuvem é homogênea em torno da reta. A escala logarítmica é a adequada para a regressão.

b) Mínimos quadrados. ln(perda) = **10,141 + 0,01796 · tempo** (erro padrão de β_1: 0,00198). Como a resposta está em logaritmo, β_1 é uma semielasticidade: cada hora a mais até a detecção aumenta a perda em e^0,01796 − 1 = **1,8%**; dez horas a mais, 19,7%. O intercepto corresponde a uma perda mediana de R$ 25,4 mil para detecção imediata (média dos tipos).

c) R^2 e erro padrão. R^2 = **0,060**; erro padrão da regressão = **1,155** (em ln). O tempo explica só 6% da variação de ln(perda). Isso não invalida a conclusão: R^2 mede quanto da dispersão o modelo explica, e não se o efeito existe. O efeito é estimado com precisão (t = 9,06; IC que exclui o zero) e tem relevância econômica. O R^2 baixo diz que o tempo não permite prever a perda de um incidente individual; o coeficiente diz que, em média, detectar mais rápido reduz a perda. A variável omitida que infla o resíduo é o **tipo de ataque**: a variância de ln(perda) é 1,418, e a variância entre as médias dos tipos é 0,484, um terço do total. Incluí-la (Questão 10-d) leva o R^2 a 0,42.

d) Hipóteses de Gauss-Markov.

- *Linearidade nos parâmetros:* plausível em logaritmo (não em reais).
- *Média zero do erro e exogeneidade:* é a hipótese mais frágil. O erro contém o tipo de ataque, mas tipo e tempo são sorteados de forma independente, o que mantém β_1 não viesado; só perde precisão.
- *Homocedasticidade:* plausível em ln (σ constante), violada em reais.
- *Erros não correlacionados:* plausível, pois os ataques são independentes.
- *Normalidade* (para a inferência exata): razoável em ln; com n = 1.288, o TCL sustenta os testes de qualquer modo.

O **viés de seleção** é o ponto de atenção: só observamos perdas de ataques que se materializaram, e o tempo de detecção influencia a materialização. A amostra de perdas tem tempos maiores que a população de ataques (média de 14,2 h nas perdas contra cerca de 9,6 h em todos os ataques). Se algum fator não observado afetasse ao mesmo tempo a materialização e a severidade, a seleção criaria correlação entre o erro e o tempo e enviesaria β_1. Neste gerador os dois sorteios são independentes dado o que observamos, e por isso a estimativa (0,018) fica perto do valor programado (0,02). Com dados reais, essa independência não estaria garantida. Além disso, a regressão descreve só ataques materializados: nada diz sobre o efeito do tempo na *chance* de haver perda, que é assunto da Questão 13.

Questão 10 — Inferência na regressão (cap. 9)

a) ANOVA.

Fonte	SQ	g.l.	QM	F
Regressão	109,43	1	109,43	82,01
Resíduo	1.715,96	1.286	1,3343	
Total	1.825,39	1.287		

F = 82,01, muito acima do crítico F(0,05; 1; 1.286) = 3,85. E $t^2 = 9{,}0561^2 = 82{,}01 = F$: na regressão simples, o teste F global e o teste t de β_1 são o mesmo teste. $R^2 = 109{,}43/1.825{,}39 = 0{,}060$.

b) IC de 95% para β_1: 0,01796 ± 1,962 × 0,00198 = **[0,0141; 0,0219]**. Contém o valor programado (0,02). Em termos percentuais, cada hora de atraso encarece a perda entre 1,4% e 2,2%.

c) Ataque detectado em 24 h.

	ln(perda)	R$
Estimativa pontual	10,572	39.036
IC 95% da média	[10,498; 10,646]	[36.257; 42.027]
Intervalo de previsão 95% (individual)	[8,305; 12,840]	[4.044; 376.846]

O IC da média diz onde está a perda típica dos ataques detectados em 24 h: entre R$ 36 mil e R$ 42 mil (em reais, a exponencial da média de ln é a mediana, não a média). O intervalo de previsão diz onde cairá *uma* perda: entre R$ 4 mil e R$ 377 mil. O primeiro tem razão de 1,16 entre os extremos; o segundo, de 93. A diferença é que o IC da média só carrega a incerteza sobre a reta, que encolhe com 1/√n, enquanto o intervalo de previsão soma a variância do próprio incidente ($s^2 = 1{,}33$), que não encolhe com mais dados. Para a gestão: sabemos bem o custo médio do atraso, mas não é possível prever o custo de um incidente específico.

d) Com dummies de tipo.

	Só tempo	Tempo + tipo
R^2	0,060	0,425
R^2 ajustado	0,059	0,422
Erro padrão da regressão	1,155	0,905
β_1	0,01796	0,02142
Erro padrão de β_1	0,00198	0,00157
IC 95% de β_1	[0,0141; 0,0219]	[0,0184; 0,0245]

Controlar o tipo multiplica o R^2 por sete, reduz o erro padrão da regressão para **0,905** (o σ programado é 0,9) e estreita o IC de β_1 em 21%. Os dois intervalos contêm 0,02. As medianas implícitas por tipo (e^(β_0 + dummy), para tempo = 0) recuperam as programadas com razões entre 0,90 e 1,08, exceto ransomware (R$ 119 mil contra R$ 150 mil; razão 0,80), o tipo com menos observações (106) e maior erro padrão. É o capítulo 10 antecipado: a variável omitida não enviesava β_1, mas inflava o resíduo.

Questão 11 — Regressão múltipla (cap. 10)

a) Modelo base.

Variável	Coeficiente	Erro padrão	t	p-valor	IC 95%	Verdadeiro
Intercepto	5,533	2,871	1,93	0,055	[−0,12; 11,18]	8,00
servicos	0,454	0,034	13,46	0,000	[0,39; 0,52]	0,50
patch	−0,037	0,033	−1,12	0,265	[−0,10; 0,03]	−0,08
treino	−0,298	0,061	−4,87	0,000	[−0,42; −0,18]	−0,20
soc	−1,798	0,434	−4,14	0,000	[−2,65; −0,94]	−1,40
trimestre	0,262	0,058	4,50	0,000	[0,15; 0,38]	0,15

b) Testes e interpretação. F = 54,0 ($p \approx 3 \times 10^{-39}$): o conjunto das variáveis é significativo. $R^2 = 0{,}489$; R^2 ajustado = 0,480; erro padrão = 3,41 ataques, para uma média de 10,6 por unidade-trimestre. O R^2 está longe do 0,97 do estudo de caso da Seção 10.7 porque aqui a resposta é uma contagem de Poisson: mesmo com a taxa verdadeira conhecida, a variância do ruído (≈ 10,7) é quase metade da variância total (22,3). Um R^2 próximo de 0,5 é o teto deste problema, e não sinal de modelo fraco.

Coeficientes parciais (mantidas as demais variáveis):

- **servicos (+0,45):** cada serviço exposto a mais acrescenta cerca de 0,45 ataque por trimestre. É a alavanca mais forte e mais precisa: reduzir a superfície de ataque.
- **treino (−0,30):** cada hora anual de conscientização evita 0,3 ataque por trimestre; levar uma unidade de 5 h para 12 h evita cerca de 2 por trimestre.
- **soc (−1,80):** unidades com SOC têm 1,8 ataque a menos por trimestre.
- **trimestre (+0,26):** a frequência cresce 0,26 ataque por trimestre em cada unidade, cerca de 1 por ano.
- **patch (−0,04):** sinal esperado, mas não significativo (p = 0,27). Com 24 unidades e patch variando só de 64% a 91%, a amostra não tem poder para isolar um efeito de −0,08. Não significa que patch seja inútil: o intervalo contém o valor verdadeiro.

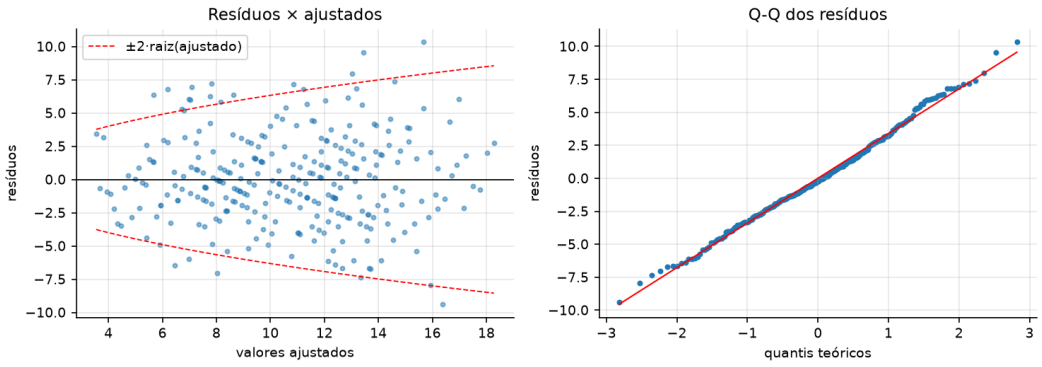
c) Estimado x verdadeiro. Os **seis** intervalos de 95% contêm o valor programado. Isso é compatível com "95% de confiança": com seis intervalos, esperam-se 5,7 acertos, e a chance de todos acertarem é da ordem de $0{,}95^6 \approx 74\%$. Vale notar que o nível de confiança é uma propriedade do procedimento em amostras repetidas, e não de um intervalo específico; a simulação é o único contexto em que dá para conferir, porque a verdade é conhecida. As estimativas pontuais erram bastante em termos relativos (treino −0,30 contra −0,20, erro de 49%; trimestre 0,26 contra 0,15, erro de 74%), mas sempre dentro da incerteza declarada.

d) Dummies de trimestre do ano e campanha (trimestre 10).

Variável	Coeficiente	Erro padrão	p-valor	Esperado pelo gerador
Q2 (vs. Q1)	−0,62	0,62	0,324	+0,71
Q3 (vs. Q1)	+0,24	0,57	0,668	0,00
Q4 (vs. Q1)	+0,87	0,59	0,139	+1,42
campanha	+3,69	0,92	0,0001	+3,28
trimestre	0,135	0,067	0,044	0,15

O ajuste melhora: R^2 ajustado sobe de 0,480 para 0,504, o AIC cai de 1.529,0 para 1.519,3 e o teste F parcial das quatro variáveis dá 4,42 (p = 0,002). O BIC piora (1.551,0 para 1.555,9), porque penaliza mais os parâmetros. Quase todo o ganho vem do indicador da **campanha**: 3,7 ataques a mais por unidade no trimestre, perto dos 3,3 esperados. As dummies sazonais não são significativas; a sazonalidade trimestral é fraca (os S_m dentro de um trimestre quase se cancelam) e Q2 saiu com sinal contrário ao esperado, dentro do erro. O efeito mais útil é indireto: com a campanha isolada, o coeficiente de **trimestre** cai de 0,262 para 0,135, bem mais perto do verdadeiro (0,15). No modelo base, a campanha no fim da amostra era lida como tendência. Por isso a Parte C usa este modelo, com campanha = 0 em 2026.

e) VIF e resíduos. Os VIF vão de 1,00 a 1,16: não há multicolinearidade.



Diagnóstico de resíduos

O Q-Q dos resíduos é aderente (Shapiro-Wilk p = 0,52). O gráfico de resíduos contra ajustados mostra o funil de forma moderada: a variância dos resíduos é 9,8 e 9,0 nos dois terços inferiores dos valores ajustados e 15,6 no terço superior. O Breusch-Pagan geral não rejeita a homocedasticidade (p = 0,11), mas a versão dirigida aos valores ajustados rejeita (p = 0,016), e a correlação de Spearman entre |resíduo| e ajustado é positiva (0,15; p = 0,010). O funil é esperado porque na Poisson a variância é igual à média: unidades com taxa prevista maior têm dispersão maior. É uma violação da homocedasticidade de Gauss-Markov que não enviesa os coeficientes, mas torna os erros padrão aproximados. A faixa de valores ajustados aqui é estreita (4 a 18), e por isso o funil não é dramático. O modelo adequado seria uma regressão de Poisson ou erros padrão robustos.

f) Sobreajuste.

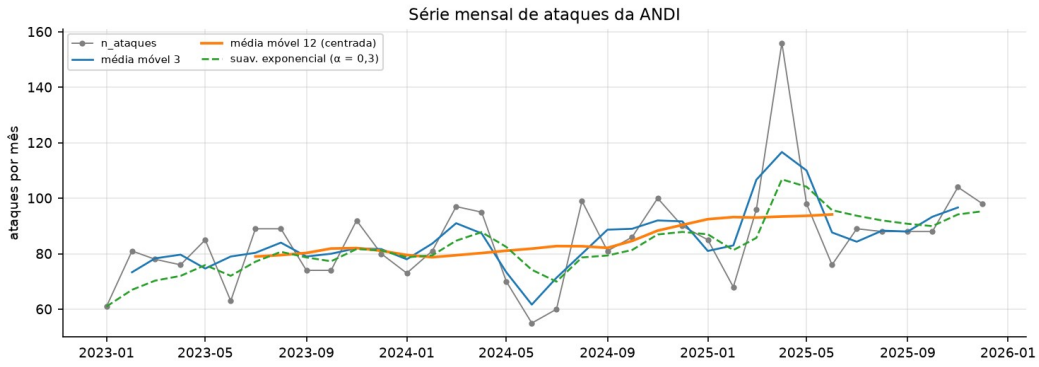
	Sem ruído	Com 5 ruídos

Parâmetros	6	11
R^2 de treino (2023–2024)	0,4635	0,4670
R^2 ajustado de treino	0,4490	0,4375
REQM de treino	3,337	3,326
REQM de teste (2025)	3,499	3,547
R^2 de teste	0,470	0,455

O sintoma aparece, em escala pequena: as cinco variáveis de ruído aumentam o R^2 de treino (sempre aumentam) e pioram o erro de teste. O R^2 ajustado cai, sinalizando corretamente que não ajudam. O efeito é modesto porque há 192 observações de treino para 11 parâmetros; com poucas observações por parâmetro, seria como na Figura 10.8. Os dois modelos subestimam 2025 em cerca de 0,6 ataque por unidade-trimestre, por causa da campanha, que nenhum deles conhece.

Questão 12 — Séries temporais (cap. 11, Parte A)

a) Tendência e sazonalidade.



Série mensal

A média mensal foi de 78,5 ataques em 2023, 82,3 em 2024 e 94,5 em 2025 (88,9 sem abril). A média móvel de 12 meses mostra a tendência de alta com clareza; a reta de mínimos quadrados dá +0,68 ataque por mês (p = 0,012), acima dos +0,40 programados (0,15 por trimestre × 24 unidades ÷ 3 meses), porque a campanha no fim da série puxa a inclinação. A média móvel de 3 meses revela um padrão que se repete a cada ano, com picos em março–abril e novembro e vales em fevereiro e junho–julho, e destaca abril de 2025 (156 ataques). A suavização exponencial (α = 0,3) acompanha o nível com atraso; o α que minimiza o erro de previsão um passo à frente é 0,20, sinal de série ruidosa em que convém suavizar bastante.

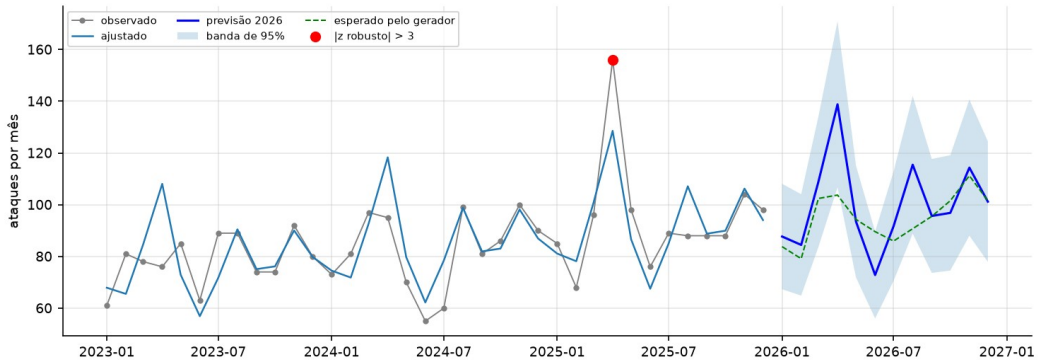
b) Decomposição. Escolhemos a forma **multiplicativa** ($Y = T \times S \times \varepsilon$): em contagens, a amplitude sazonal cresce com o nível (o desvio dentro do ano subiu de 9,8 em 2023 para 15,2 em 2024), e a sazonalidade como percentual do nível é a leitura natural.

Mês	Jan	Fev	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez
Estimado	0,91	0,87	1,11	**1,41**	0,94	0,73	0,91	1,14	0,94	0,95	1,11	0,98
Programado	0,90	0,85	1,10	1,10	1,00	0,95	0,90	0,95	1,00	1,05	1,15	1,05

Os índices acertam bem cinco meses (jan, fev, mar, jul, nov; erro até 0,04), mas a correlação com os S_m é só 0,62 e o erro absoluto médio é 0,09. Há dois problemas. A média móvel centrada perde 6 meses em cada ponta, e cada índice é a média de apenas dois anos. E abril está contaminado: o índice de 1,41 mistura a sazonalidade verdadeira (1,10) com a campanha de 2025. Como os índices são normalizados para média 1, o excesso de abril rebaixa os demais (junho: 0,73 contra 0,95). Três anos são pouco para estimar 12 índices.

c) ACF. O limite de significância é $\pm 1{,}96/\sqrt{36} = \pm 0{,}327$. Nenhuma autocorrelação das defasagens 1 a 9, 11 e 12 o ultrapassa: $r_1 = 0{,}26$ e $r_{12} = 0{,}20$ são positivos, como se espera com tendência e sazonalidade anual, mas não significativos. Só a defasagem 10 passa por pouco (−0,35), sem interpretação e compatível com acaso em 12 testes. A série é quase ruído em torno de uma tendência suave: os ataques de um mês pouco informam sobre o seguinte. Isso é coerente com contagens de Poisson independentes; a dependência temporal entra pela taxa, e não por contágio entre meses. A sazonalidade existe (amplitude de ±15%), mas é fraca frente ao ruído de uma contagem em torno de 85 (desvio de Poisson ≈ 9, ou 11%).

d) Previsão de 2026 e regra dos 3σ.



Previsão de 2026

A previsão combina a tendência linear da série dessazonalizada com os índices sazonais; a banda de 95% vem do intervalo de previsão da reta e se alarga com o horizonte.

2026	Jan	Fev	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez	Total
Previsão	88	84	109	139	93	73	92	115	96	97	114	101	1.201
Limite inferior	67	65	84	107	72	56	71	89	74	74	88	78	
Limite superior	108	104	134	171	115	90	113	142	118	119	141	125	
Esperado pelo gerador	84	79	102	104	94	90	86	91	96	102	111	102	1.139

O total previsto (1.201) fica 5,4% acima do esperado pelo gerador (1.139), por causa da tendência superestimada. Mês a mês, o maior erro é abril (139 contra 104): o método projeta a campanha de 2025 como se fosse sazonalidade.

Regra dos 3σ (método clássico). Com σ dos resíduos = 11,5, o resíduo de abril de 2025 é +27,5, ou z = **2,39**. **O método não encontra a campanha.** Também não dispara falso alarme a 3σ. A 2σ, sinaliza os três abris: 2025 por excesso (+2,39) e 2023 e 2024 por falta (−2,79 e −2,03). É mascaramento: a anomalia entrou na estimativa do próprio índice de abril e inflou o σ, e então se esconde e faz os abris normais parecerem baixos.

Complemento robusto. Recalculamos os índices pela mediana dos três anos (razão à reta de tendência), e trocamos o σ estimado pelo desvio de Poisson, √(valor ajustado). O índice de abril cai para 1,13, o esperado para abril de 2025 passa a 103 e o z vai a **5,22**: a campanha é detectada, e é o único alarme (o segundo maior |z| é 2,30). A lição para um SOC é que um detector calibrado em dados que contêm a anomalia aprende a anomalia; a linha de base precisa ser robusta ou estimada em período limpo.

Questão 13 — Classificação (cap. 11, Parte B)

Treino: 1.929 ataques de 2023–2024 (42,3% materializados). Teste: 1.134 ataques de 2025 (41,6%).

a) Regressão logística.

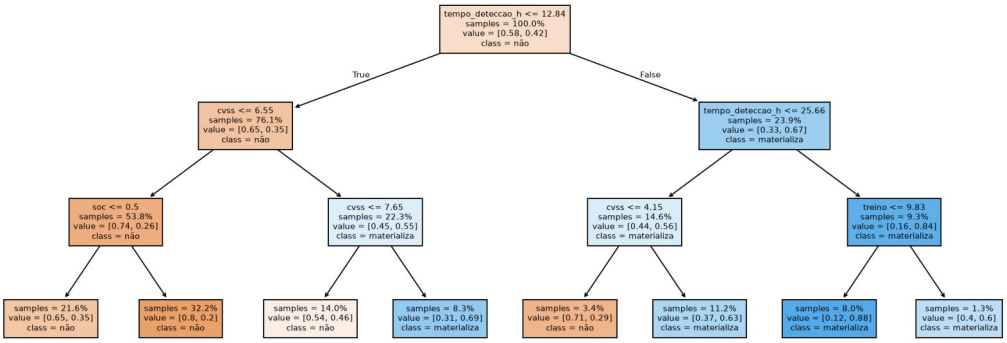
Variável	β estimado	e^β	Erro padrão	IC 95% de β	β verdadeiro	e^β verdadeiro
Intercepto	−2,753	0,064	0,242	[−3,23; −2,28]	−2,80	0,061
cvss	0,431	1,539	0,035	[0,36; 0,50]	0,45	1,568
tempo_detecca o_h	0,057	1,059	0,006	[0,045; 0,070]	0,06	1,062
soc	−0,767	0,465	0,115	[−0,99; −0,54]	−0,80	0,449
treino	−0,082	0,922	0,016	[−0,11; −0,05]	−0,08	0,923
fora_expediente	0,637	1,890	0,110	[0,42; 0,85]	0,50	1,649

Todos os coeficientes são significativos ($p < 0,001$) e os seis intervalos contêm o valor programado. Em razões de chances: cada ponto de CVSS multiplica a chance de materialização por 1,54; cada hora de atraso na detecção, por 1,06 (uma demora de 12 h dobra a chance: $1,059^{12} \approx 2,0$); ter SOC reduz a chance a menos da metade (0,46); cada hora de treinamento reduz 8%; um ataque fora do expediente tem chance 89% maior, além do efeito que

já exerce pelo tempo de detecção. A recuperação dos parâmetros é melhor que na regressão de frequência porque aqui há 1.929 observações individuais, contra 24 perfis de unidade.

b) Dummies de tipo. Pelo gerador **não** deveriam ser significativas: o tipo não entra na equação da Etapa A4; ele só afeta a materialização por meio do CVSS, que já está no modelo. O teste de razão de verossimilhança das cinco dummies confirma: 9,01 com 5 g.l., p = 0,109, e o AIC piora (2.179,9 para 2.180,9). Uma dummy isolada, ransomware, aparece significativa (p = 0,017); com cinco testes a 5%, um falso positivo tem 23% de chance, e o teste conjunto é o correto. O contraste que ensina: sozinho, o tipo é fortemente associado à materialização (p ≈ 2×10^{-18}), mas esse efeito desaparece ao controlar o CVSS. O tipo é um efeito mediado.

c) Árvore de decisão (profundidade 3).



Árvore de decisão

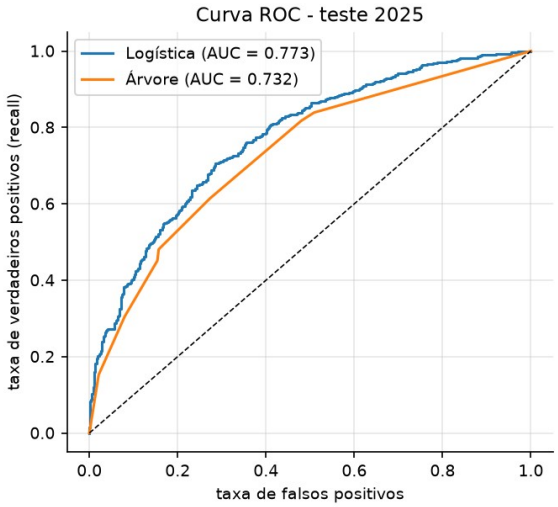
Regras (proporção de materializados no treino entre parênteses):

- Se tempo ≤ 12,8 h e cvss ≤ 6,55: **não materializa**; com SOC (20%), sem SOC (35%).
- Se tempo ≤ 12,8 h e 6,55 < cvss ≤ 7,65: **não materializa** (46%).
- Se tempo ≤ 12,8 h e cvss > 7,65: **materializa** (69%).
- Se 12,8 h < tempo ≤ 25,7 h e cvss ≤ 4,15: **não materializa** (29%).
- Se 12,8 h < tempo ≤ 25,7 h e cvss > 4,15: **materializa** (63%).
- Se tempo > 25,7 h: **materializa** (88% com treino ≤ 9,8 h; 60% acima).

A árvore usa tempo de detecção (importância 0,51) e CVSS (0,40), um pouco de SOC e treino, e ignora fora_expediente, cujo efeito já chega pelo tempo. As regras são legíveis para um analista: ataque que demora mais de um dia para ser detectado é perda quase certa.

d) Avaliação em 2025 (limiar 0,5).

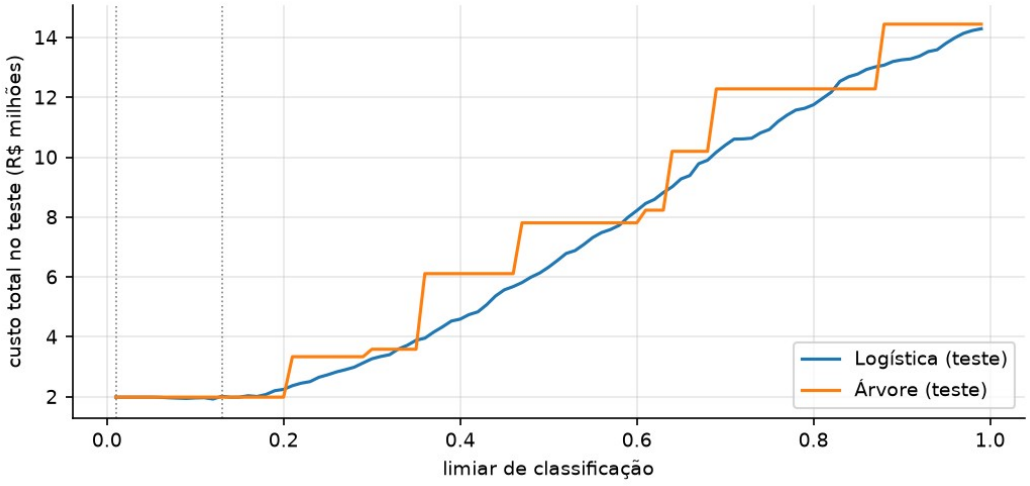
	Logística	Árvore
VP / FP / FN / VN	279 / 140 / 193 / 522	227 / 104 / 245 / 558
Acurácia	0,706	0,692
Precisão	0,666	0,686
Recall	0,591	0,481
F1	0,626	0,565
AUC	0,773	0,732



Curvas ROC

A logística vence em quase tudo, o que é esperado: o gerador é exatamente um modelo logístico, e a árvore aproxima uma fronteira linear com degraus. A árvore tem precisão um pouco maior, à custa de deixar passar mais da metade das perdas (recall de 0,48). Uma AUC de 0,77 é o limite do problema, não do modelo: a materialização é um sorteio de Bernoulli, e nem o modelo verdadeiro passaria muito disso. O desempenho em 2025 é parecido com o do treino: não há sinal de mudança de conceito na materialização (a campanha alterou a frequência, não a probabilidade).

e) Limiar de custo mínimo. Falso negativo: R$ 30.599 (perda mediana em 2023–2024); falso positivo: R$ 3.000. O limiar teórico é c_FP/(c_FP + c_FN) = **0,089**: vale alarmar sempre que a probabilidade de perda passar de 9%.



Custo por limiar

Logística	Limiar 0,5	Limiar 0,13 (escolhido no treino)
FP / FN	140 / 193	580 / 9
Recall	0,591	0,981
Precisão	0,666	0,444
Custo no teste	R$ 6,33 mi	R$ 2,02 mi

Baixar o limiar de 0,5 para 0,13 corta o custo em 68%: troca 184 falsos negativos (R$ 5,6 mi) por 440 falsos positivos (R$ 1,3 mi). É a tensão α × β do capítulo 7: o limiar é a fronteira da região de rejeição; baixá-lo aumenta α (falsos alarmes) e reduz β (perdas não vistas). Como o erro Tipo II custa dez vezes mais, o ótimo aceita muito mais Tipo I. O limiar 0,5 só é ótimo quando os dois erros custam o mesmo.

Um resultado que precisa ser dito: com esses custos, **investigar todos os ataques custaria R$ 1,99 mi**, um pouco menos que o melhor limiar da logística (R$ 2,02 mi); e o limiar ótimo da árvore é "alarmar tudo". Com prevalência de 42% e razão de custos de 10 para 1, quase nenhum ataque tem probabilidade abaixo de 9%, e a triagem pouco agrega. O classificador passaria a valer com investigação mais cara, prevalência menor (como no cenário com controles) ou capacidade limitada de analistas, caso em que serviria para ordenar a fila.

Parte C — SMC de risco e decisão

Questão 14 — Perda anual de 2026 e o pacote de controles

a) Modelar. A perda anual agregada é

$L = \Sigma_u \Sigma_k \Sigma_{j=1..N_{u,k}} X_{u,k,j}$, com $N_{u,k} \sim \text{Poisson}(\lambda_u \cdot \pi_k \cdot p_{u,k})$ e $X \sim \text{Lognormal}(\mu_{k,s}, \sigma_k)$,

em que u é a unidade, k o tipo de ataque e s o status de SOC da unidade. Nenhum parâmetro do gerador é usado; cada insumo vem da Parte B:

- **Frequência λ_u (Questão 11).** Soma das previsões dos trimestres 13 a 16 para o perfil da unidade, pelo modelo 11-d com campanha = 0. Escolhemos o 11-d porque ele separa a campanha da tendência; o modelo base preveria 1.222 ataques em 2026, e o 11-d prevê **1.095** (em 2025 foram 1.134, incluindo a campanha).
- **Participação dos tipos π_k.** Frequências relativas observadas.
- **Materialização $p_{u,k}$ (Questão 13).** Média da probabilidade prevista pela logística para ataques do tipo k, com o SOC e o treino da unidade. CVSS e fora_expediente vêm dos ataques observados daquele tipo; o tempo de detecção vem dos ataques observados em unidades com o mesmo status de SOC.
- **Severidade (perdas.csv).** Lognormal por tipo. Os parâmetros diretos (média e desvio de ln perda) estão abaixo. Para o efeito do SOC, estimamos $\ln(\text{perda}) = \mu_k + \delta \cdot \text{soc}$: **$\delta = -0{,}248$** (erro padrão 0,057; $p \approx 2 \times 10^{-5}$), ou seja, perdas 22% menores em unidades com SOC.

Tipo	n	$\hat{\mu}$	$\hat{\sigma}$	Mediana $e^{\hat{\mu}}$ (R$)	Média implícita (R$)	Média amostral (R$)
Phishing	386	9,855	1,021	19.047	32.081	34.144
Força bruta	193	9,536	0,896	13.847	20.677	20.529
Malware	220	10,588	0,926	39.660	60.878	62.053
Exploração de vuln.	245	10,998	0,969	59.757	95.537	97.260
DDoS	138	10,513	0,940	36.802	57.266	56.124
Ransomware	106	11,985	1,022	160.370	270.392	295.111

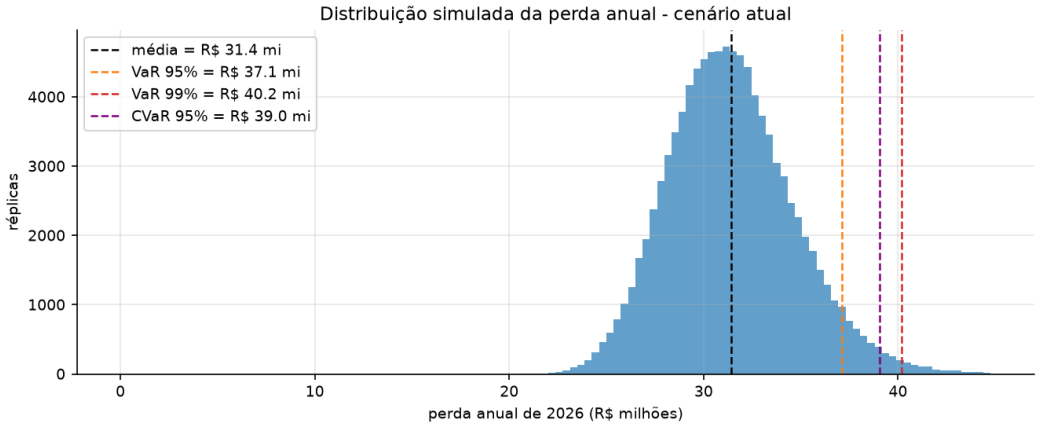
Thinning. Se os ataques chegam como Poisson de taxa λ e cada um, de forma independente, é do tipo k com probabilidade π_k e se materializa com probabilidade p, então os eventos de perda de cada tipo são Poisson de taxa $\lambda \cdot \pi_k \cdot p$, independentes entre si. Isso permite sortear direto o número de perdas, sem simular os ataques que não geram perda. A hipótese exigida é que a materialização de um ataque não dependa da dos outros. Usar a probabilidade *média* é exato para a contagem (uma mistura de Bernoullis independentes tem média $\bar{p}$), desde que a severidade seja sorteada da distribuição das perdas, como fazemos.

Insumos agregados:

	Atual	Com controles	Variação
Ataques por ano ($\Sigma\lambda$)	1.094,8	757,6	−30,8%
Probabilidade média de materialização	0,424	0,194	−54,3%
Eventos de perda por ano	464,1	146,7	−68,4%
Severidade média (R$)	67.742	64.210	−5,2%
Perda anual esperada, analítica (R$ mi)	31,44	9,42	−70,0%

Coerência com o histórico: de 2023 a 2025 houve 429 perdas e R$ 31,2 mi por ano, em média.

b) Sortear, calcular, analisar (100.000 réplicas).



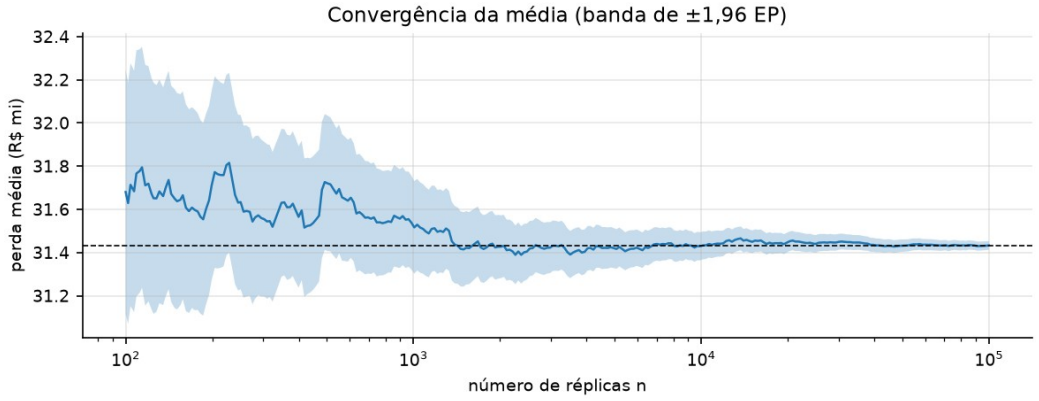
Distribuição da perda anual

Métrica	Cenário atual	Interpretação
Perda média anual	R$ 31,43 mi	Expectativa de perda em 2026
Mediana	R$ 31,23 mi	Valor central
Desvio-padrão	R$ 3,27 mi	Variação de um ano para outro
VaR 95%	R$ 37,11 mi	Só superada em 5% dos anos
VaR 99%	R$ 40,19 mi	Só superada em 1% dos anos
CVaR 95%	R$ 39,05 mi	Perda média nos 5% piores anos
P(perda > R$ 30 mi)	65,3%	Probabilidade de perda relevante

A ANDI deve esperar perder cerca de R$ 31 mi em 2026, com 5% de chance de passar de R$ 37 mi; nos piores anos, a perda média seria de R$ 39 mi. A distribuição anual é bem menos assimétrica que a de uma perda individual: é a soma de cerca de 460 eventos, e o TCL atua. Mesmo assim a cauda direita é mais longa (o VaR 99% está 2,7 desvios acima da média, contra 2,33 numa Normal).

c) Convergência.

n	Média (R$ mi)	Erro padrão (R$ mi)	VaR 95% (R$ mi)	EP relativo ao de n = 1.000	1/√(n/1.000)
1.000	31,512	0,1098	37,502	1,000	1,000
4.000	31,413	0,0526	37,291	0,479	0,500
16.000	31,458	0,0261	37,217	0,238	0,250
64.000	31,435	0,0129	37,115	0,118	0,125
100.000	31,433	0,0103	37,112	0,094	0,100



Convergência

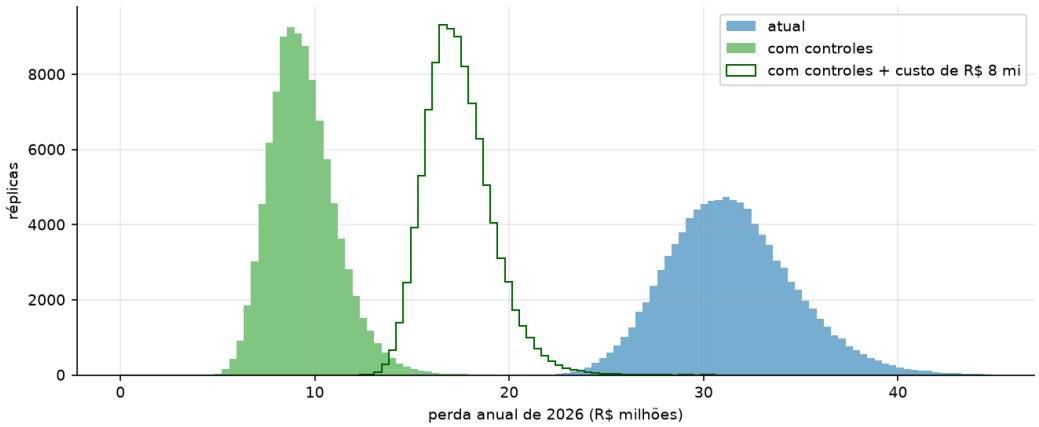
O erro padrão cai na proporção 1/√n: cada vez que n quadruplica, o erro cai à metade (0,110 → 0,053 → 0,026 → 0,013). Com 100.000 réplicas, a média tem erro de R$ 10 mil (0,03%). O VaR 95% estabiliza mais devagar, porque depende só das réplicas de cauda; a partir de 64.000 muda na quarta casa. O erro de simulação é desprezível diante do erro de modelo medido no item (g).

d) Cenário com controles. Patch = 95%, treino = 12 h e SOC em todas as unidades, realimentando os três modelos:

- *Frequência:* a regressão 11-d prevê 757,6 ataques (−31%).

- *Materialização:* a logística recebe soc = 1 e treino = 12, e o tempo de detecção de cada ataque passa a ser sorteado dos tempos observados em unidades com SOC. A probabilidade média cai de 0,424 para 0,194.
- *Severidade:* como o SOC reduz o tempo de detecção e cada hora encarece a perda, as unidades que ganham SOC passam a usar $\mu_k + \delta$ (perdas 22% menores). O valor de δ é coerente com o caminho alternativo: $\beta_1 \times$ diferença de tempo médio entre perdas com e sem SOC = 0,0214 × (5,72 − 18,38) = −0,271.

Métrica	Atual	Com controles	Redução
Perda média anual	R$ 31,43 mi	R$ 9,42 mi	R$ 22,02 mi (70%)
Mediana	R$ 31,23 mi	R$ 9,24 mi	R$ 21,99 mi (70%)
VaR 95%	R$ 37,11 mi	R$ 12,48 mi	R$ 24,64 mi (66%)
VaR 99%	R$ 40,19 mi	R$ 14,36 mi	R$ 25,83 mi (64%)
CVaR 95%	R$ 39,05 mi	R$ 13,66 mi	R$ 25,39 mi (65%)
P(perda > R$ 30 mi)	65,3%	0,0%	−65,3 p.p.



Atual x com controles

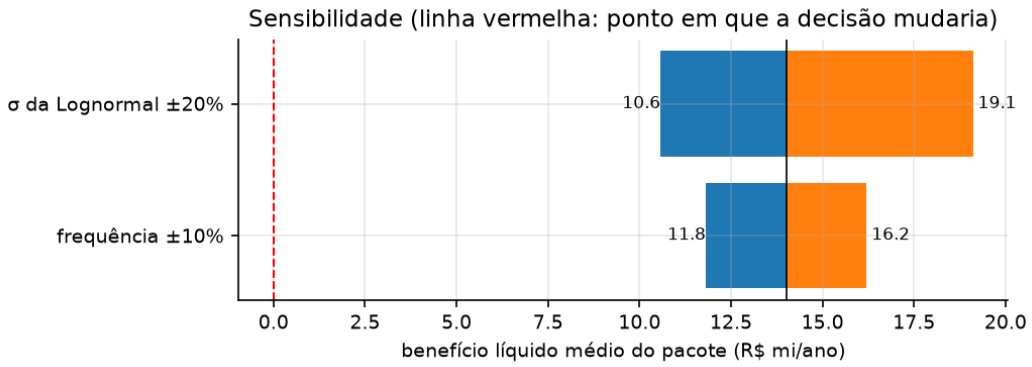
e) Decisão.

- Redução da perda média: R$ 22,02 mi por ano (erro padrão de simulação: R$ 0,007 mi).
- **ROI = (22,02 − 8,00)/8,00 = 175%.** Benefício líquido médio: R$ 14,0 mi por ano.
- P(perda com controles + R$ 8 mi > perda sem controles) = **0,00%** em 100.000 réplicas pareadas com números aleatórios comuns: mesmo somando o custo, a distribuição com controles fica inteira à esquerda da atual.
- Custo máximo que ainda se paga na média: **R$ 22,0 mi por ano**.

Os números aleatórios comuns usam o mesmo U para a contagem de Poisson e o mesmo z para a severidade de cada evento nos dois cenários. A diferença entre cenários fica livre do ruído comum, e por isso o erro padrão da redução (R$ 0,007 mi) é menor que o da própria média (R$ 0,010 mi).

f) Sensibilidade.

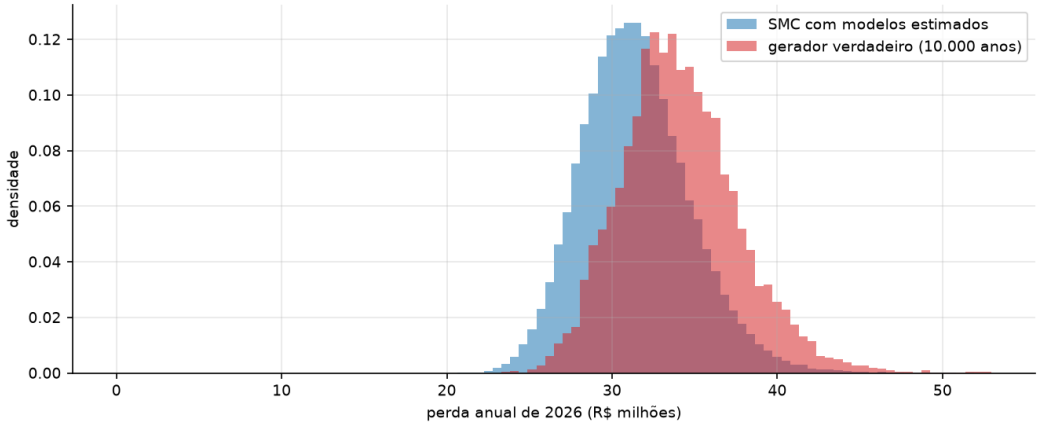
σ da Lognormal	Frequência	Perda média atual (R$ mi)	Redução (R$ mi)	Benefício líquido (R$ mi)	ROI	Decisão
−20%	−10%	23,85	16,72	8,72	109%	investir
−20%	base	26,51	18,58	10,58	132%	investir
−20%	+10%	29,15	20,42	12,42	155%	investir
base	−10%	28,28	19,81	11,81	148%	investir
base	base	31,43	22,02	14,02	175%	investir
base	+10%	34,55	24,20	16,20	203%	investir
+20%	−10%	34,84	24,39	16,39	205%	investir
+20%	base	38,71	27,11	19,11	239%	investir
+20%	+10%	42,55	29,79	21,79	272%	investir



Tornado

A decisão não muda em nenhum dos nove casos. No pior (σ 20% menor e frequência 10% menor), o ROI ainda é 109%. O σ pesa mais que a frequência: ±20% em σ move o benefício líquido entre R$ 10,6 mi e R$ 19,1 mi, contra R$ 11,8 mi a R$ 16,2 mi para ±10% na frequência, porque σ entra no expoente da média da Lognormal ($e^{\mu + \sigma^2/2}$). Para a decisão se inverter, a redução de perda teria de cair de R$ 22 mi para menos de R$ 8 mi, uma queda de 64%.

g) Erro de modelo. Rodamos o gerador da Parte A com os parâmetros verdadeiros para 2026 (t = 37 a 48, sem campanha) em 10.000 anos.



Erro de modelo

Métrica (R$ mi)	SMC estimada (b)	Gerador verdadeiro	Erro
Média	31,43	34,12	−7,9%
Mediana	31,23	33,81	−7,6%
Desvio-padrão	3,27	3,66	−10,7%
VaR 95%	37,11	40,39	−8,1%
VaR 99%	40,19	44,09	−8,8%
CVaR 95%	39,05	42,92	−9,0%
CVaR 99%	42,15	47,78	−11,8%
P99,9	44,76	52,96	−15,5%
P(perda > R$ 30 mi)	65,3%	88,1%	−22,8 p.p.

A SMC baseada em modelos estimados **subestima** a distribuição inteira, e o erro cresce em direção à cauda: −8% na média, −9% no VaR 99%, −12% no CVaR 99%, −15% no percentil 99,9. O erro padrão da média verdadeira é R$ 0,04 mi, portanto a diferença de R$ 2,7 mi não é ruído de simulação. Decomposição:

Componente	Estimado	Verdadeiro	Erro
Ataques por ano	1.094,8	1.140,0	−4,0%
Probabilidade de materialização	0,424	0,426	−0,6%
Severidade média (R$)	67.742	70.209	−3,5%

- **Frequência (−4%).** É erro de estimação da regressão, com 24 unidades e muito ruído de Poisson. Vale notar que é sorte de amostra: o modelo base erraria +7%, para o outro lado.
- **Materialização (−0,6%).** A logística, estimada com quase 2.000 ataques, praticamente acerta.

- **Severidade (−3,5% na média, mais na cauda).** É erro de especificação. A Lognormal por tipo ignora que a perda verdadeira é Lognormal *condicionada ao tempo de detecção*. O tempo é Exponencial, e e^(0,02 × tempo) tem cauda mais pesada que a de uma Lognormal. O ajuste por tipo acerta o centro e perde a ponta, e é por isso que o erro cresce na cauda.

Há ainda um motivo estrutural para a cauda ser subestimada: a SMC trata os parâmetros estimados como certos. A incerteza sobre os coeficientes não entra na dispersão simulada.

A decisão sobrevive ao erro: com os parâmetros verdadeiros, a redução da perda média é de R$ 23,3 mi e o ROI é de 192%, contra R$ 22,0 mi e 175% estimados. O modelo errou o nível em cerca de 8%, para menos nos dois cenários, e acertou a diferença entre eles.

Síntese

19. O gerador reproduz o que foi programado; as diferenças observadas têm o tamanho do erro de simulação σ/√n.
20. A perda por incidente é aproximadamente Lognormal: mediana de R$ 32 mil, média de R$ 73 mil, e 10% dos incidentes respondem por 52% do valor.
21. Com 3.063 ataques, os modelos recuperam os parâmetros dentro dos intervalos de confiança; a precisão é boa onde há muitas observações (logística) e fraca onde há poucas (24 perfis de unidade).
22. Três métodos falharam de modo instrutivo: o backtesting de Kupiec não rejeitou um modelo que sabemos desatualizado; a regra dos 3σ não achou a campanha por mascaramento; a triagem por classificador quase não reduz custo com a prevalência atual.
23. A SMC de decisão estima perda de R$ 31,4 mi em 2026 (VaR 95% de R$ 37,1 mi) e recomenda o pacote (ROI de 175%). Ela subestima a perda verdadeira em cerca de 8%, mais na cauda, sem alterar a decisão.